

MA8020 Tekniska beräkningar

Något om optimering

Mikael Hindgren



HÖGSKOLAN
I HALMSTAD

4 december 2025

Optimering

Grundprinciper

- *Definition:* Användning av matematiska modeller och metoder för att finna det "bästa alternativet" - *Optimum*
- *Målet:* Kunskaper som krävs för att fatta det bästa möjliga beslutet
- *Standardmodellens komponenter:*
 - *Målfunktion:* f ska minimeras/maximeras
 - *Designvariabler:* Variablerna som styr resultatet
- *Motivering:*
 - Minimera vikt
 - Maximera resursallokering
 - Minimera energiförbrukning
 - Maximera vinst
 - Minimera tid
 - Maximera prestanda
 - Minimera risk
 - ...

Optimering

Begränsningar och modellers komplexitet

- *Obegränsad optimering*: Designvariablerna är fria (sällan i praktiken).
- *Begränsad optimering* (vanligast):
 - Inkluderar naturliga begränsningar sk bivillkor ($g(x) \leq 0$).
 - Lösningen söks i den *tillåtna regionen* (feasible region).
 - Form: Minimera/Maximera $f(x)$ under bivillkor/begränsningar (s.t.).
- *Modellernas komplexitet*:
 - *Linjär Programmering (LP)*: Linjär målfunktion och linjära begränsningar.
 - *Icke-linjära modeller (NP)*: Målfunktion och/eller begränsningar är icke-linjära \Rightarrow svårare att hantera.
- *Utmaning*: Inga generella garantier kan ges för att uppnå ett *globalt optimum* (eller ens ett lokalt) i de mest allmänna modellerna.

Optimering

Optimum hos kontinuerliga funktioner

Sats 1 (Satsen om största och minsta värde)

Om $D \subset \mathbb{R}^n$ är en **kompakt** mängd och $f : D \rightarrow \mathbb{R}$ en kontinuerlig funktion på D så gäller följande:

- f antar sitt största ($\max f$) och minsta ($\min f$) värde i D (**Extremvärdessatsen**).
- Den punkt $\mathbf{x}_0 \in D$ där ett extremvärde antas är av följande typ
 - 1 **Kritisk punkt** i det inre av D där $\nabla f(\mathbf{x}_0) = \mathbf{0}$.
 - 2 **Singulär punkt** i det inre av D där $\nabla f(\mathbf{x}_0)$ är odefinierad.
 - 3 **Randpunkt**: $\mathbf{x}_0 \in \partial D$.

Exempel 1

Bestäm maximum för $f(x, y) = xy^2$ då $x^2 + y^2 \leq 1$, $x \geq 0$, $y \geq 0$.

- Kritiska punkter: $\nabla f = (y^2, 2xy) = (0, 0) \Rightarrow (x, y) = (0, 0)$
- Randpunkter:

$$x = 0 \Rightarrow f(x, y) = g_1(y) = 0$$


$$y = 0 \Rightarrow f(x, y) = g_2(x) = 0$$

$$y^2 = 1 - x^2 \Rightarrow f(x, y) = g_3(x) = x(1 - x^2)$$

$$\Rightarrow g'_3(x) = -3x^2 + 1 = 0$$

$$\Leftrightarrow (x, y) = \left(\pm \sqrt{\frac{1}{3}}, \sqrt{\frac{2}{3}} \right)$$

$$\therefore f_{\max} = f\left(\sqrt{\frac{1}{3}}, \sqrt{\frac{2}{3}}\right) = \frac{2}{3\sqrt{3}}.$$



Optimering

Riktungsderivata

Definition 1

Om \mathbf{v} är en enhetsvektor ($|\mathbf{v}| = 1$) är **riktningsderivatan** av funktionen $f(\mathbf{x})$ i punkten \mathbf{a} i riktning \mathbf{v}

$$\frac{df}{d\mathbf{v}}(\mathbf{a}) = \lim_{h \rightarrow 0} \frac{f(\mathbf{a} + h\mathbf{v}) - f(\mathbf{a})}{h}$$

Kedjeregeln ger ett mer användbart uttryck:

$$\frac{df}{d\mathbf{v}}(\mathbf{a}) = \nabla f(\mathbf{a}) \cdot \mathbf{v}$$

Exempel 2

Bestäm riktningsderivatan av $f(x, y) = x^2 + 2xy - 3y^2$ i punkten $\mathbf{a} = (1, 2)$ i riktning $\mathbf{v} = \frac{1}{\sqrt{2}}(1, -1)$.

$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (2x + 2y, 2x - 6y)$$


$$\Rightarrow \nabla f(1, 2) \cdot \mathbf{v} = (6, -10) \cdot \frac{1}{\sqrt{2}}(1, -1) = 8\sqrt{2}.$$

Definition 2 (Konvex, konkav)

- Funktionen $f : C \rightarrow \mathbb{R}$ är **konvex** om $x, y \in C$, $\lambda \in [0, 1]$ om

$$f((1 - \lambda)x, \lambda y) \leq (1 - \lambda)f(x) + \lambda f(y)$$

- Om olikheten är strikt ($<$) är f **strikt konvex**.
- Om $-f$ är (strikt) konvex är f (strikt) **konkav**.



Optimering

Maxima och minima


Definition 3

Funktion f har ett:

- **globalt maximum** i x^* om $f(x^*) \geq f(x)$ för alla $x \in D_f$,
- **lokalt maximum** om det finns liten omgivning U av x^* så att $f(x^*) \geq f(x)$ för $x \in U$.

Om olikheten är sträng ($<$) är det ett **strikt maximum**.

Globalt och lokalt minimum definieras på motsvarande sätt.



Optimering

Maxima och minima

När är en stationär punkt \mathbf{x}_0 en lokal maximi, minimi- eller sadelpunkt?

Taylorutveckling i flera variabler:

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \underbrace{(\nabla f(\mathbf{x}_0))^T}_{=0}(\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^T H(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + \dots$$

$$H(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix} \leftarrow \text{Hessianska matrisen ("hessianen")}$$

$$\Rightarrow f(\mathbf{x}) - f(\mathbf{x}_0) \approx \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^T H(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0)$$

Tecknet på $f(\mathbf{x}) - f(\mathbf{x}_0)$ dvs. om $f(\mathbf{x}) \geq f(\mathbf{x}_0)$ eller $f(\mathbf{x}) \leq f(\mathbf{x}_0)$ beror på H .

Optimering

Maxima och minima

Definition 4

Om A är en $n \times n$ -matris och $\mathbf{v} \in \mathbb{R}^n$ så är A

- **positivt definit** om $\mathbf{v}^T A \mathbf{v} > 0$ for alla $\mathbf{v} \neq 0$,
- **positivt semidefinit** om $\mathbf{v}^T A \mathbf{v} \geq 0$ for alla $\mathbf{v} \neq 0$,
- **negativt definit** om $\mathbf{v}^T A \mathbf{v} < 0$ for alla $\mathbf{v} \neq 0$,
- **negativt semidefinit** om $\mathbf{v}^T A \mathbf{v} \leq 0$ for alla $\mathbf{v} \neq 0$,
- **indefinit** om A varken är positivt eller negativt semidefinit.

Sats 2

- Om $\nabla f(\mathbf{x}_0) = 0$ och $H(\mathbf{x}_0)$ är positivt (definit) semidefinit så har f ett (strikt) lokalt minimum i \mathbf{x}_0 .
- Om f är konvex och $\nabla f(\mathbf{x}_0) = 0$ har f globalt minimum i \mathbf{x}_0 .

Optimering


Konvexa mängder

Definition 5


En mängd $D \subset \mathbb{R}^n$ är konvex om, för varje par av punkter \mathbf{x} och \mathbf{y} i mängden, hela det rätta linjesegmentet mellan \mathbf{x} och \mathbf{y} också ligger inuti D :

$$D \text{ är konvex} \Leftrightarrow \forall \mathbf{x}, \mathbf{y} \in D, \forall \lambda \in [0, 1] : \lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in D$$

Konvex mängd



Icke-Konvex mängd



Optimering

Konvexa funktioner

Sats 3

Låt M vara en konvex mängd, f deriverbar två gånger och H f :s hessian.

- $f(x)$ är en konvex funktion på M om H är positivt semidefinit
- $f(x)$ är en strikt konvex funktion på M om H är positivt definit
- $f(x)$ är en konkav funktion på M om H är negativt semidefinit
- $f(x)$ är en strikt konkav funktion på M om H negativt definit

Sats 4

Låt λ_i vara egenvärdena till hessianen H . Om alla

- $\lambda_i \geq 0$ är H positivt semidefinit
- $\lambda_i > 0$ är H positivt definit
- $\lambda_i \leq 0$ är H negativt semidefinit
- $\lambda_i < 0$ är H negativt definit

Optimering

Problemformulering och villkor för lokala och globala minima.

Ett allmänt optimeringsproblem kan formuleras som

$$(G) \quad \begin{array}{ll} \min & f(x) \\ \text{s.t.} & x \in F \quad (\text{s.t. "subject to"}) \end{array}$$

där $f : F \rightarrow \mathbb{R}$ och $F \subseteq \mathbb{R}^n$.

- F kallas **lösningssområde** (feasible region) och f **målfunktion** (objective function)
- Om $F \subset \mathbb{R}^n$ har vi **optimering med bivillkor** och om $F = \mathbb{R}^n$ **optimering utan bivillkor**.
- I explicit matematisk form kan (G) representeras som

$$(M) \quad \begin{array}{ll} \min & f(x) \\ \text{s.t.} & \begin{cases} g_i(x) \leq 0, \quad i = 1, \dots, m \\ h_j(x) = 0, \quad j = 1, \dots, p \\ x \in \mathbb{R}^n \end{cases} \end{array}$$

dvs $F = \{x \in \mathbb{R}^n \mid g_i(x) \leq 0, h_j(x) = 0\}$.

Optimering

Kuhn-Tucker-villkor för lokalt minimum.

Sats 5 (Kuhn-Tucker-villkoren)

För det matematiska optimeringsproblemet:

$$(M) \quad \begin{aligned} &\min \quad f(x) \\ &\text{s.t.} \quad \begin{cases} g_i(x) \leq 0, \quad i = 1, \dots, m \\ h_j(x) = 0, \quad j = 1, \dots, p \\ x \in \mathbb{R}^n \end{cases} \end{aligned}$$

är följande villkor nödvändiga för lokalt minimum i x^* om ett lämpligt regularitetsvillkor (t.ex. LICQ) är uppfyllt (KT 1-4):

- ❶ *Primal tillåtlighet:* $g_i(x^*) \leq 0, h_j(x^*) = 0$
- ❷ *Komplementaritet:* $\lambda_i g_i(x^*) = 0$
- ❸ *Dual tillåtlighet:* $\lambda_i^* \geq 0, \mu_j^* \in \mathbb{R}$
- ❹ *Stationaritet:* $\nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(x^*) = \mathbf{0}$

Optimering

Kuhn-Tucker-villkor för lokalt minimum.

Förklaringar:

- **Primal tillåtlighet:** Lösningen x^* måste vara tillåten (feasible) i det ursprungliga primala problemet (M) .
- **Komplementaritet:** Villkoret $\lambda_i^* g_i(x^*) = 0$ innebär att antingen är multiplikatorn λ_i^* noll, eller så är olikhetsbivillkoret $g_i(x^*)$ aktivt (mättat).
- **Dual tillåtlighet:** Lagrangemultiplikatorerna λ_i^* för olikhetsbivillkoren måste vara icke-negativa ($\lambda_i^* \geq 0$).
- **Stationaritet:** Villkoret $\nabla_x L(x^*, \lambda^*, \mu^*) = \mathbf{0}$ säger att x^* är en stationär punkt till Lagrangefunktionen L .

Anm:

- Om endast likhetsvillkor ($h_j(x) = 0$) finns, reduceras KKT-villkoren till *Lagrangevillkoren*: $h_j(x^*) = 0$ och Stationaritetsvillkoret (4).
- Om M är ett *konvext optimeringsproblem* (konvex f , konvexa g_i , linjära h_j), är KT-villkoren *tillräckliga* för att garantera ett globalt minimum i x^* , under förutsättning att $\lambda^* \geq 0$ (Dual tillåtlighet) är uppfyllt.

Optimering utan bivillkor

Polynomapproximation

Förutsättningar:

- $f(x)$ är konvex i intervallet $I = [x_1, x_3] \Rightarrow$ har minimum
- Funktionsvärden kan beräknas för alla $x \in I$ och $x_1 < x_2 < x_3$


Approximera $f(x)$ med ett polynom $p_2(x)$ av grad 2:

$$\begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ c_2 \end{pmatrix} = \begin{pmatrix} f_1 \\ f_2 \\ f_3 \end{pmatrix} \Leftrightarrow p_2(x) = c_0 + c_1x + c_2x^2 \Rightarrow p_2'(x) = c_1 + 2c_2x$$

$$\Rightarrow x_4 = -\frac{c_1}{2c_2} = \dots = \frac{f_1(x_2^2 - x_3^2) + f_2(x_3^2 - x_1^2) + f_3(x_1^2 - x_2^2)}{2(f_1(x_2 - x_3) + f_2(x_3 - x_1) + f_3(x_1 - x_2))}$$

Iteration:

- 1 Om $x_4 < x_2$:
 - Om $f(x_4) < f(x_2)$: $x_3 = x_2$, $x_2 = x_4$
 - Annars ($f(x_4) \geq f(x_2)$): $x_1 = x_4$
- 2 Annars ($x_4 > x_2$):
 - Om $f(x_4) < f(x_2)$: $x_1 = x_2$, $x_2 = x_4$
 - Annars ($f(x_4) \geq f(x_2)$): $x_3 = x_4$
- 3 Fortsätt tills $|x_3 - x_1| < \varepsilon$



Optimering utan bivillkor

Polynomapproximation


Exempel 3

Följande data är given:

x	0	1	2
f	3	2	6

Bestäm ett approximativt värde på minimum för $f(x)$ i $[0, 2]$ med hjälp av $p_2(x)$.

Mathematica: $p_2(x) = 3. - 3.5x + 2.5x^2$, $x_4 = 0.7$, $f_{min} \approx 1.775$



Optimering utan bivillkor


Bisektionsmetoden (Bolzano Search)

Förutsättningar:

- $f(x)$ är konvex i $[a, b]$
- $f'(x)$ är kontinuerlig i $[a, b]$ (och kan beräknas)
- $f'(a)f'(b) < 0$

Iteration:

- 1 Beräkna $f'(c)$ där $c = \frac{b+a}{2}$
- 2 Om $|f'(c)| < \epsilon$ accepteras c som minimum
Annars: Om $f'(c) > \epsilon$, $b = c$ annars $a = c$
- 3 Iterera tills $|f'(c)| < \epsilon$



Metoden konvergerar till globalt minimum om f är konvex (i hela D_f), annars till ett lokalt minimum om det är en stationär punkt.

Exempel 4

Minimera $f(x) = x^2 - \frac{4x}{3} + 1$ med Bisektionsmetoden.

Optimering utan bivillkor

Newton's metod

På samma sätt som vi kan hitta en rot till $f(x) = 0$ med Newton-Raphsons metod kan vi hitta en rot till $f'(x) = 0$. Tillräckliga villkor för konvergens:

- $f(x) \in C^2$ i $[a, b]$
- Ett lokalt minimum x^* måste existera tillräckligt nära startpunkten x_0
- $f(x)$, $f'(x)$ och $f''(x)$ kan beräknas i $[a, b]$.
- $f''(x) > 0$ i en omgivning av x^*

Iterationsformel:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Exempel 5

Minimera $f(x) = x^2 - \frac{4x}{3} + 1$ med Newtons metod.

Anm: Sekantmetoden är ett alternativ som undviker beräkning av $f''(x)$:

$$x_{k+1} = x_k - f'(x_k) \frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})}$$

Optimering utan bivillkor: Funktioner av flera variabler

Sökmeter

En vanlig grupp av metoder for optimering är **sökmeter**. De kan alla formuleras enligt följande iteration

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}, k = 0, 1, 2, 3...$$

där

- $\mathbf{x}^{(0)}$ är **startpunkt**
- α_k är **steglängd**
- $\mathbf{d}^{(k)}$ är **sökriktning**

Valet av α_k och $\mathbf{d}^{(k)}$ definierar de olika metoderna.

Om f är en kvadratisk funktion, dvs. kan skrivas som

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T H \mathbf{x} + \mathbf{c}^T \mathbf{x} + b \quad \text{är} \quad \alpha_k = -\frac{\nabla f(\mathbf{x}_k)^T \mathbf{d}_k}{\mathbf{d}_k^T H \mathbf{d}_k} \quad (H \text{ konstant})$$

- Det är det enklaste icke-linjära fallet där linjesökningsproblemet (att hitta optimalt α_k) har en exakt analytisk lösning.
- Alla C^2 -funktioner kan approximeras med en kvadratisk funktion (Taylor-utveckling) och fallet representerar därför det lokala beteendet hos alla optimeringsproblem.

Optimering utan bivillkor: Funktioner av flera variabler

Sökmeter

- *Steglängden*: I det allmänna fallet måste α_k bestämmas approximativt.
- *Linjesökningsproblemet*: När sökriktningen \mathbf{d}_k har valts, reduceras problemet till ett endimensionellt problem: Hitta det α som minimerar funktionen längs den valda riktningen:

$$\min_{\alpha} f(\mathbf{x}_k + \alpha \mathbf{d}_k) \quad (1)$$

- Eftersom (1) är ett optimeringsproblem i en variabel (α) utan bivillkor, kan tidigare 1D-metoder användas t.ex. kvadratisk interpolation.

Optimering utan bivillkor: Funktioner av flera variabler

Brantaste lutningsmetoden (*Steepest Descent*)

Metoden använder $\alpha_k = 1$ och $\mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)} = \mathbf{x}^{(k)} - \nabla f(\mathbf{x}^{(k)}), \quad k = 0, 1, 2, 3, \dots$$

- Gradienten $\nabla f(\mathbf{x}_k)$ pekar i den riktning där funktionen f ökar snabbast i punkten \mathbf{x}_k .
- Vektorns norm (längd), $\|\nabla f(\mathbf{x}_k)\|$, är lika med den maximala tillväxthastigheten (riktningsderivatan) i denna riktning.

$\Rightarrow -\nabla f(\mathbf{x}_k)$ är riktningen för brantaste lutningen dvs. där funktionen minskar snabbast.

Optimering utan bivillkor: Funktioner av flera variabler

Newton's metod

Metoden är en generalisering av 1D-fallet ($x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$) med

$$\mathbf{d}^{(k)} = -H(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)}) \quad \text{och} \quad \alpha_k = 1$$

vilket ger

$$\mathbf{x}^{(k+1)} = \mathbf{x}_k + \alpha_k \mathbf{d}_k = \mathbf{x}^{(k)} - H(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)}), \quad k = 0, 1, 2, 3, \dots$$

- Newton's metod är en direkt generalisering av Newton-Raphsons metod för rotsökning och löser systemet av icke-linjära ekvationer: $\nabla f(\mathbf{x}) = \mathbf{0}$.
- Om hessianen H är icke-singulär, erhålls kvadratisk konvergens (mycket snabb).
- Om startpunkten \mathbf{x}_0 är långt från minimum $\hat{\mathbf{x}}$, används ofta en steglängd $0 < \alpha_k < 1$ (bestäms via linjesökning) i de första iterationerna (Dämpad Newtonmetod).
- Samma försiktighet med steglängden ($\alpha_k < 1$) bör även användas för Brantaste lutningsmetoden.


Optimering utan bivillkor: Funktioner av flera variabler

Newton's metod

Exempel 6

Vi minimerar $f(x, y) = (x + 0.3y)^2 + (2(x^2 + y^2 - 1) - 1)^2$

```
In[ ]:= Remove["Global`*"]
f[x_, y_] := (x + 0.3 y)^2 + (2 (x^2 + y^2 - 1) - 1)^2;
Plot3D[f[x, y], {x, -1.3, 1.8}, {y, 0.5, 1.7}, ColorFunction -> Hue]
FindMinimum[f[x, y], {{x, -1.1}, {y, 0.8}}]
```



Out[]:= $\{4.47878 \times 10^{-19}, \{x \rightarrow -0.351928, y \rightarrow 1.17309\}\}$


Vi väljer $\alpha_k = 0.8$ och startpunkt $\mathbf{x}^{(0)} = (-1.1, 0.8)$:

Optimering utan bivillkor: Funktioner av flera variabler

Newton's metod

Exempel 6 (Forts.)

```
Remove["Global`*"]
f = (x + 0.3 y)^2 + (2 (x^2 + y^2 - 1) - 1)^2;
alpha = 0.8;
Print["∇f = ", G = FullSimplify[D[f, {{x, y}}]]];
Print["H = ", H = FullSimplify[D[f, {{x, y}, 2}]]];
{x, y} = {-1.1, 0.8};
route = {{x, y}};
Do[{x, y} = {x, y} - alpha*Inverse[H].G; AppendTo[route, {x, y}], {10}];
Print["Route = ", Transpose[route]];
pl = ContourPlot[f, {x, -1.3, -0.2}, {y, 0.75, 1.25},
  Contours -> 6 (Range[0, 6, 0.25]/6)^4,
  PlotPoints -> 50,
  ColorFunction -> Hue,
  Epilog -> {Blue, Line[route], PointSize[0.02], Point/@ route}
];
Print["fmin = ", f]
Show[pl]
```



$$\nabla f = \left\{ 16. \left(x^3 + 0.0375 y + x \left(-1.375 + y^2 \right) \right), 16. \left(0.0375 x - 1.48875 y + x^2 y + y^3 \right) \right\}$$

$$H = \left\{ \left\{ -22 + 48 x^2 + 16 y^2, 0.6 + 32 x y \right\}, \left\{ 0.6 + 32 x y, 48. \left(-0.49625 + 0.333333 x^2 + y^2 \right) \right\} \right\}$$

$$\text{Route} = \left\{ \left\{ -1.1, -0.928934, -0.706371, -0.545316, -0.432761, -0.377824, -0.35827, -0.353271, -0.3522, -0.351982, -0.351939 \right\}, \left\{ 0.8, 0.858773, 1.04653, 1.1184, 1.15598, 1.16842, 1.17203, 1.17287, 1.17305, 1.17308, 1.17309 \right\} \right\}$$

$$f_{\min} = 1.79546 \times 10^{-10}$$

Optimering med bivillkor

Lagrangerelaxation

Det matematiska problemet

$$(M) \quad \begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & \begin{cases} g_i(x) \leq 0, \quad i = 1, \dots, m \\ x \in X \end{cases} \end{aligned} \quad (2)$$

där X , f och g_i är konvexa kan skrivas om med **Lagrangerelaxationen**

$$(M_L) \quad \begin{aligned} \min \quad & \left(f(x) + \sum_{i=1}^m \lambda_i g_i(x) \right) \\ \text{s.t.} \quad & x \in X \end{aligned}$$

- λ_i är **Lagrangemultiplikatorer**
- **Lagrangefunktionen** definieras som: $L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x)$
- Lagrangerelaxationen (M_L) är en relaxation till M om $\lambda_i \geq 0$
- Ett nödvändigt villkor för att x^* ska vara en optimal lösning till (2) är att det existerar $\lambda^* \geq 0$ så att stationaritetsvillkoret är uppfyllt:

$$\nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) = \mathbf{0}$$

Optimering med bivillkor

Lagranges metod för likhetsvillkor

Vi ska nu studera problemet

$$\begin{aligned}
 & \min f(x) \\
 (L) \quad & \text{s.t.} \begin{cases} g_i(x) = 0, i = 1, \dots, m \\ x \in X \end{cases}
 \end{aligned} \tag{3}$$

och tillhörande Lagrangefunktion:

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x)$$

- För likhetsvillkor (3) finns ingen teckenrestriktion på λ_i ($\lambda_i \in \mathbb{R}$).
- För att hitta stationära punkter behöver vi lösa ekvationssystemet

$$\nabla_{x,\lambda} L(x, \lambda) = \mathbf{0} \Leftrightarrow \begin{cases} \nabla f(x) + \sum_{i=1}^m \lambda_i \nabla g_i(x) = \mathbf{0}, \\ g_i(x) = 0, i = 1, \dots, m. \end{cases}$$

Optimering med bivillkor

Lagranges metod för likhetsvillkor

Exempel 7

Bestäm den punkt på planet $x - y + 2z = 6$ som är närmast origo.

Avståndet från punkten (x, y, z) till origo är $d = \sqrt{x^2 + y^2 + z^2}$.

Optimeringsproblem:

$$(L) \quad \begin{array}{ll} \min & f(x, y, z) = x^2 + y^2 + z^2 \\ \text{s.t.} & g(x, y, z) = x - y + 2z - 6 = 0 \end{array}$$

$$\Rightarrow L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x}) = x^2 + y^2 + z^2 + \lambda(x - y + 2z - 6)$$

Vi får

$$\nabla_{\mathbf{x}, \lambda} L(\mathbf{x}, \lambda) = \mathbf{0} \Leftrightarrow \begin{cases} \nabla f(\mathbf{x}) + \lambda \nabla g(\mathbf{x}) = \mathbf{0} \\ g(\mathbf{x}) = 0 \end{cases}$$

$$\Leftrightarrow \begin{cases} (2x + \lambda, 2y - \lambda, 2z + 2\lambda) = \mathbf{0} \\ x - y + 2z - 6 = 0 \end{cases}$$

$$\Leftrightarrow (x, y, z, \lambda) = (1, -1, 2, -2) \Rightarrow f_{\min} = f(1, -1, 2) = 6 \Rightarrow d = \sqrt{6}$$

Optimering med bivillkor

Lagranges metod för likhetsvillkor

Exempel 8

Lös optimeringsproblemet med Newtons metod:

$$\begin{aligned} \min \quad & f(x, y, z) = x^2 + y^2 + z^2 \\ (L) \quad \text{s.t.} \quad & \begin{cases} g_1(x, y, z) = x + y + z + 3 = 0 \\ g_2(x, y, z) = x + 2y - 3z - 6 = 0 \end{cases} \end{aligned}$$

Vi använder Newtons metod:

$$L(\mathbf{v}) = L(x, y, z, \lambda_1, \lambda_2) = f(x, y, z) + \lambda_1 g_1(x, y, z) + \lambda_2 g_2(x, y, z)$$

$$\mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} - H(\mathbf{v}^{(k)})^{-1} \nabla L(\mathbf{v}^{(k)}), \quad k = 0, 1, 2, 3, \dots$$

Resultat från Mathematica: $\mathbf{x}^* = (-7, -1, 5)$, $f_{\min} = 75$.

Endast en iteration krävs!

Anm: L är kvadratisk \Rightarrow hessianen H är konstant. Om inte så är fallet måste H^{-1} beräknas i varje steg.

Optimering med bivillkor

Straffmetoder för icke-linjära likhetsvillkor

För $f : \mathbb{R}^n \rightarrow \mathbb{R}$ och $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ och optimeringsproblemet

$$(P_E) \quad \begin{array}{ll} \min & f(x) \\ \text{s.t.} & g(x) = 0 \end{array}$$

inför vi en obegränsad **strafffunktion** som bestraffar överträdelse av bivillkoren:

$$P(x, r) = f(x) + \frac{1}{r} g(x)^T g(x)$$

- **Straffparametern** $r > 0$
- Termen $g(x)^T g(x) = \|g(x)\|_2^2$ är ett mått på hur mycket bivillkoren $g(x) = 0$ överträds
- Idén är att minimera $P(x, r)$ utan bivillkor

Optimering med bivillkor

Straffmetoder för icke-linjära likhetsvillkor

- Lösningen hittas genom att lösa en *sekvens av obegränsade problem*:

$$(P_k) \quad \min_{x \in \mathbb{R}^n} P(x, r_k)$$

- Vi väljer en sekvens r_k där $r_k \rightarrow 0$ när $k \rightarrow \infty$.
- *Konvergens*: Om $x^*(k)$ är lösningen till (P_k) , gäller (under lämpliga villkor):

$$x^*(k) \rightarrow x^* \quad \text{och} \quad \frac{2}{r_k} g(x^*(k)) \rightarrow \lambda^* \quad \text{när } r_k \rightarrow 0.$$

Anm:

- Kräver lösning av en *sekvens av problem*.
- När $r_k \rightarrow 0$ blir hessianen för $P(x, r_k)$ extremt illa-konditionerad (stort konditionstal) vilket leder till numerisk instabilitet.

Optimering med bivillkor

Straffmetoder för icke-linjära likhetsvillkor

Exempel 9

Lös följande problem med straffmetod:

$$\begin{array}{ll} \min & f(\mathbf{x}) = \frac{1}{2}(x_2^2 - x_1^2) \\ \text{s.t.} & x_1 = 1 \end{array}$$

Vi har $g(\mathbf{x}) = x_1 - 1$ och bildar strafffunktionen

$$P(\mathbf{x}, r) = f(\mathbf{x}) + \frac{1}{r}g(\mathbf{x})^T g(\mathbf{x}) = \frac{1}{2}(x_2^2 - x_1^2) + \frac{1}{r}(x_1 - 1)^2$$

$$\nabla_{\mathbf{x}} P = \left(-x_1 + \frac{2(x_1 - 1)}{r}, x_2 \right) = \mathbf{0} \Leftrightarrow \mathbf{x}^*(r) = \left(\frac{2}{2-r}, 0 \right) \rightarrow \mathbf{x}^* = (1, 0) \text{ då } r \rightarrow 0$$

För $r < 2$ är hessianen

$$H(\mathbf{x}, r) = P_{\mathbf{xx}}(\mathbf{x}, r) = \begin{pmatrix} -1 + \frac{2}{r} & 0 \\ 0 & 1 \end{pmatrix}$$

positivt definit $\Rightarrow P$ konvex $\Rightarrow \mathbf{x}^*$ globalt minimum och $f_{\min} = -\frac{1}{2}$.

Optimering med bivillkor

Straffmetoder för icke-linjära likhetsvillkor

Anm:

- $\frac{2}{r}g(x^*(r)) = \frac{1}{r}(\frac{2}{2-r} - 1) \rightarrow 1 = \lambda^*$ då $r \rightarrow 0$
- Konditionstalet: $\kappa(H) = \left| \frac{\mu_{\max}}{\mu_{\min}} \right| = \left| \frac{-1+\frac{2}{r}}{1} \right| \rightarrow \infty$ då $r \rightarrow 0$ (μ egenvärden)
- Detta är nackdelen med (yttre) straffmetod: När $r \rightarrow 0$, konvergerar problemet mot \mathbf{x}^* men $\kappa(H) \rightarrow \infty$. Detta gör problemet mycket svårt att lösa numeriskt på grund av instabilitet och långsam konvergens.

Exempel 10

Lös optimeringsproblemet med straffmetod:

$$\begin{aligned} \min \quad & f(x, y, z) = x^2 + y^2 + z^2 \\ \text{s.t.} \quad & \begin{cases} g_1(x, y, z) = x + y + z + 3 = 0 \\ g_2(x, y, z) = x + 2y - 3z - 6 = 0 \end{cases} \end{aligned}$$

$$\text{Sätt: } P(\mathbf{x}, r) = f(\mathbf{x}) + \frac{1}{r}(g_1(\mathbf{x})^2 + g_2(\mathbf{x})^2)$$

Optimering med bivillkor

Straffmetoder för icke-linjära olikhetsvillkor

För $f : \mathbb{R}^n \rightarrow \mathbb{R}$ och $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ och optimeringsproblemet

$$(P_I) \quad \begin{array}{ll} \min & f(x) \\ \text{s.t.} & g(x) \leq 0 \end{array}$$

inför vi en **yttre strafffunktion**

$$P(x, r) = f(x) + \frac{1}{r} g^+(x)^T g^+(x) \quad \text{där} \quad g_i^+(x) = \begin{cases} g_i(x) & \text{om } g_i(x) > 0 \\ 0 & \text{annars} \end{cases}$$

- Bestraffning sker om och endast om punkten x ligger utanför det tillåtna området (d.v.s., när $g_i(x) > 0$ för något i).
- Metoden kallas **yttre straffmetod** eftersom optimallösningen x^* närmas **utifrån** det tillåtna området ($x^*(r) \rightarrow x^*$ då $r \rightarrow 0^+$) genom att lösa $\min P(x, r)$ för successivt mindre r .

Optimering med bivillkor

Straffmetoder för icke-linjära *olikhetsvillkor*

- Om det inte är möjligt att beräkna f eller g utanför det tillåtna området kan en **inre straffmetod** (eller **barriärmetod**) användas. Ex:

1 Invers barriärfunktion: $P(x, r) = f(x) - r \sum_{i=1}^m \frac{1}{g_i(x)}$

2 Logaritmisk barriärfunktion: $P(x, r) = f(x) - r \sum_{i=1}^m \ln(-g_i(x))$

Båda har en "barriär" vid randen av det tillåtna området

- När x närmar sig gränsen till det tillåtna området ($g_i(x) \rightarrow 0^+$):
 - Invers barriär: $-r \cdot (1/g_i(x)) \rightarrow +\infty$
 - Logaritmisk barriär: $-r \cdot \ln(-g_i(x)) \rightarrow +\infty$

Detta skapar en oändligt hög kostnad (barriär) vid gränsen vilket effektivt hindrar optimeringsalgoritmen från att nå eller korsa det icke-tillåtna området.

- $x^*(r) \rightarrow x^*$ **inifrån** när straffparametern $r \rightarrow 0^+$.
- Inre barriärmetoder håller alltid sökningen efter optimum strikt innanför det tillåtna området.

Optimering med bivillkor

Straffmetoder för icke-linjära olikhetsvillkor

Exempel 11

Bestäm

$$\begin{array}{ll} \min & f(x) = x^3 + x \\ \text{s.t.} & x \geq 2 \end{array}$$

med inre straffmetod och **invers barriärfunktion**.

Vi har olikhetsvillkoret $g(x) = 2 - x \leq 0$.

$$\text{Strafffunktion: } P(x, r) = f(x) - r \frac{1}{g(x)} = x^3 + x - r \frac{1}{2 - x}.$$

$$\begin{aligned} \text{Stationära punkter: } \frac{dP}{dx} &= 3x^2 + 1 - r \frac{1}{(2 - x)^2} = 0 \Leftrightarrow r = (3x^2 + 1)(2 - x)^2 \\ \therefore r &\rightarrow 0^+ \Leftrightarrow x \rightarrow 2^+ \end{aligned}$$

Optimering med bivillkor

Straffmetoder för icke-linjära olikhetsvillkor

Exempel 12

Samma problem igen: Bestäm

$$\begin{array}{ll} \min & f(x) = x^3 + x \\ \text{s.t.} & x \geq 2 \end{array}$$

med inre straffmetod och **logaritmisk barriärfunktion**.

Vi har fortfarande olikhetsvillkoret $g(x) = 2 - x \leq 0$.

$$\text{Strafffunktion: } P(x, r) = f(x) - r \ln(-g(x)) = x^3 + x - r \ln(-(2 - x)).$$

$$\begin{aligned} \text{Stationära punkter: } \frac{dP}{dx} &= 3x^2 + 1 - r \frac{1}{x-2} = 0 \Leftrightarrow r = (3x^2 + 1)(x - 2) \\ \therefore r &\rightarrow 0^+ \Leftrightarrow x \rightarrow 2^+ \end{aligned}$$